PJ1

注意事项

- 本项目提交截止为2026.5.10 23:59分。请将报告和代码通过elearning提交。
- 提交的报告旨在记录进行的实验及主要研究结果，请务必对实验成果进行详细阐释。请将项目内容整合为单一PDF文档，并与源代码一并提交。报告和代码打包压缩为一个.zip/.tar.gz格式文件。请在报告中注明姓名与学号。
- 关于截止日期与延期惩罚：请依据各子项目规定的截止时间提交报告和代码。接受延期提交，但每延迟一周将被扣除总分的10%作为处罚。

背景和说明

问题背景

视觉-语言模型中，图像与文本的对齐方式并不只有一种。典型代表包括：

- **Contrastive alignment**：以 CLIP 类方法为代表
- **Matching-based alignment**：以 BLIP 类方法为代表
- **Projection / Query-based alignment**：以 BLIP-2 中的 Q-Former 为代表

本项目希望在**统一数据集**与**统一评测协议**下，对这三类跨模态对齐范式进行比较，并分析它们在检索、生成和表征空间上的差异。CLIP 的核心是把图像特征和文本特征投影到同一潜空间并计算相似度；BLIP 同时面向理解与生成；BLIP-2 由视觉编码器、Q-Former 和语言模型组成，可生成文本并提取图像特征。

通过使用三个模型进行retrieval、captioning 和 representation analysis 的实验结果给出证据与解释，回答核心问题：

为什么纯 contrastive learning 在组合泛化与细粒度对齐上可能存在瓶颈?

本项目以调用公开预训练模型并进行统一评测为主，不要求重新预训练模型；如进行微调，可作为附加探索内容。

数据集说明

本项目统一使用 **COCO val2017** 及其 caption annotations。COCO 是一个大规模图像理解数据集，支持 captioning 等任务。COCO val2017共包含5000张图片，每张图片由人工标注的5条caption。

可以通过以下方式获取：

```
# 官网下载
wget http://images.cocodataset.org/zips/val2017.zip
wget http://images.cocodataset.org/annotations/annotations_trainval2017.zip
```

若官网下载失败或者速度慢，可以尝试以下方法：

```
# modelscope下载
https://www.modelscope.cn/datasets/codexie/coco_val2017/files

# huggingface下载
https://huggingface.co/datasets/pcuenq/coco-2017-mirror/tree/main
```

模型说明

项目可以参考**LAVIS**，它支持数据集下载、模型加载、训练、评测和benchmark，覆盖retrieval、captioning等任务。

- **Contrastive**：CLIP 或 OpenCLIP
- **Matching**：BLIP retrieval
- **Projection / Query-based**：BLIP-2

CLIP模型可以通过OpenCLIP或者Transformers等库加载调用，BLIP/BLIP2可通过LAVIS或Transformers调用。

任务一：图文检索（Image-Text Retrieval）

在统一的COCO val2017数据集上，比较三类模型的图文检索能力。

任务需要完成两个方向：

- **Text-to-Image Retrieval**
- **Image-to-Text Retrieval**

并报告以下指标：

- Recall@1
- Recall@5
- Recall@10

建议实现方式

1. 对所有图像提取 image embedding
2. 对所有 caption 提取 text embedding
3. 计算相似度矩阵
4. 分别做 text→image 与 image→text 排序
5. 统计 Recall@K

Retrieval task的实现可以参考LAVIS Tasks中的实现方式，也鼓励自行实现统一的 embedding extraction 与 Recall@K evaluator。。

任务二：生成能力比较（Image Captioning Comparison）

任务需要对于统一的一批 COCO val2017 图像：

- 生成 caption
- 与 ground-truth captions 对比评测
- 给出定量结果与定性案例

评价指标报告

至少报告：

- BLEU-4
- CIDEr

鼓励补充：

- METEOR
- ROUGE-L
- SPICE

pycocoevalcap 是 COCO caption generation 的 Python 3 评测工具，支持上述常见指标。

本任务仅要求比较 BLIP 与 BLIP-2 的 caption generation 能力，不要求 CLIP/OpenCLIP 生成 caption。

任务三：表征分析（Representation Analysis）

部分 A：Embedding Visualization

从每个模型中提取**用于跨模态对齐或检索的最终图像表示与文本表示**，对同一批样本做降维可视化（PCA / t-SNE / UMAP 任选其一或多个）。

请至少分析下面 3 个问题：

1. 同一图文对在 embedding space 中是否更接近
2. 不同模型的图像点与文本点是否更容易混合在一起
3. 语义簇结构是否不同，例如是否出现更明显的“主物体簇”或“场景簇”

为保证可视化可读性，可以在image-text pair的子集上（如100-1000对）完成 embedding visualization；默认每张图像选取 1 条 caption 参与该部分分析。

部分 B：Nearest-Neighbor Case Study

请分别做：

- 给定图像，找最相近的若干文本
- 给定文本，找最相近的若干图像

并分析下面几个现象：

1. 模型是否过度依赖“主物体”
2. 是否容易忽略关系词、属性词、计数词
3. 是否容易把“语义接近但不匹配”的 hard negatives 拉得很近

可选加强

可以自行设计一小组“组合泛化”案例，例如：

- `red bus` vs `blue bus`
- `two dogs` vs `one dog`
- `man behind horse` vs `man riding horse`

观察各模型在这些细粒度差异上的检索表现和邻近样本分布。